



SUJET STATAPP 292 - 2026-2027



Sujet proposé par : NIAKH Fallou - fallou.niakh@ensae.fr
Organisme : CREST ENSAE
Catégorie : Actuariat
Sujet :
Semantic Credit Risk Pricing with Large Language Models

Description du sujet :

Ce projet vise à appliquer les représentations sémantiques des grands modèles de langage (LLMs) au problème de scoring de crédit. En s'inspirant des travaux récents de Blier-Wong & Kusmenko (2026) sur la tarification en assurance, les étudiants construiront un pipeline en deux étapes : chaque emprunteur est d'abord décrit par un prompt en langage naturel (sérialisation de ses variables structurées), dont on extrait un embedding dense via un LLM pré-entraîné ; cet embedding est ensuite réduit par ACP et utilisé comme vecteur de covariables dans un modèle de régression logistique. Le projet s'appuie sur le German Credit Data (public, Kaggle) et inclut un volet de fine-tuning avec une perte contrastive alignée sur la similarité de risque entre emprunteurs, ainsi qu'une analyse de sensibilité aux formats de prompt et aux attributs protégés.

Données du sujet :

Pour les données du sujet :

Nom : German Credit Data

Source : UCI Machine Learning Repository / Kaggle

Taille : 1 000 observations, 10 variables

Variable cible : Risque de crédit binaire (bon / mauvais payeur)

Variables disponibles : statut du compte courant, durée du crédit, historique de paiement, objet du crédit, montant emprunté, épargne, ancienneté professionnelle, taux d'effort, situation personnelle, type de logement, âge, qualification professionnelle, etc.

Accès : Public, librement téléchargeable

Modèles envisagés du sujet :

Pour les modèles envisagés du sujet :

Modèles de référence (baseline)

- 1) Régression logistique avec encodage one-hot des variables structurées
- 2) Gradient Boosting (XGBoost / LightGBM)

Modèles d'embedding (représentation)

- 1) Qwen3-Embedding-0.6B (open source, déployable localement)

- 2) Qwen3-Embedding-8B
- 3) Gemini Embedding (Google)
- 4) Llama-Embed-Nemotron-8B

Modèle de prédiction (downstream)

- 1) Régression logistique / GLM logistique alimenté par les embeddings réduits par ACP

Fine-tuning

- 1) Low-Rank Adaptation (LoRA) avec perte contrastive CoSENT alignée sur la similarité de risque de crédit entre emprunteurs

Bibliographie du sujet :

Pour la bibliographie du sujet :

Article source

Blier-Wong, C. & Kusmenko, D. (2026). Semantic insurance pricing with large language models. arXiv:2606.29371.

Représentation learning & embeddings en actuariat

Blier-Wong, C. et al. (2021). Rethinking representations in P&C actuarial science with deep neural networks. arXiv:2102.05784.

Fine-tuning & LoRA

Hu, E. J. et al. (2022). LoRA: Low-rank adaptation of large language models. ICLR 2022.

Embeddings LLM pour données tabulaires

Koloski, B. et al. (2025). LLM embeddings for deep learning on tabular data. arXiv:2502.11596.

Kasneci, E. & Kasneci, G. (2024). Enriching tabular data with contextual LLM embeddings. arXiv:2411.01645.

Hegselmann, S. et al. (2023). TabLLM: Few-shot classification of tabular data with large language models. AISTATS 2023.

Modèles d'embedding

Zhang, Y. et al. (2025). Qwen3 embedding: Advancing text embedding and reranking through foundation models. arXiv:2506.05176.

Lee, J. et al. (2025). Gemini embedding: Generalizable embeddings from Gemini. arXiv:2503.07891.

Perte contrastive

Huang, X. et al. (2024). CoSENT: Consistent sentence embedding via similarity ranking. IEEE/ACM TASLP.

Notation du sujet :

Commentaires :

