



SUJET STATAPP 309 - 2026-2027

Sujet proposé par : HU François - francois.hu@ekimetrics.com

Organisme : Ekimetrics

Catégorie : Actuariat

Sujet :

Apprentissage de lois a priori par transfert entre portefeuilles : une approche de meta-learning bayésien

Description du sujet :

Les modèles hiérarchiques estiment conjointement des paramètres propres à plusieurs groupes tout en exploitant leur structure commune. Ce partage partiel d'information stabilise les estimations des groupes faiblement dotés (en actuariat, c'est exactement la théorie de la crédibilité de Bühlmann, où la prime pondère l'expérience individuelle du segment et celle du portefeuille).

Ce cadre suppose que tous les groupes soient estimés simultanément. En pratique la situation est séquentielle : on dispose de modèles estimés sur des cas passés, et l'on veut modéliser un nouveau cas qui n'en faisait pas partie. La question devient celle d'un transfert.

Cela relève du meta-learning bayésien. Une phase d'apprentissage sur N cas construit une distribution des hyperparamètres, puis une phase d'adaptation l'utilise comme loi a priori pour le cas $N+1$. Le cadre théorique existe, mais sans caractérisation empirique du gain ni réponse à la question pratique du volume d'expérience nécessaire.

Le projet aborde trois questions :

1. Combien de cas faut-il ? En faisant varier N , on mesure le gain sur le cas suivant : erreur de prédiction, largeur des intervalles, vitesse de convergence. La courbe de gain sature nécessairement. Où ?
2. Que transférer ? Trois stratégies sont comparées : la tendance centrale des hyperparamètres, leur dispersion également, ou leur distribution a posteriori complète. Cette dernière est plus correcte car elle propage l'incertitude issue de l'apprentissage, mais elle est rarement mise en œuvre.
3. Quand le transfert nuit-il ? Si le nouveau cas s'écarte de la population d'apprentissage, une loi a priori informative le tire au mauvais endroit, avec une confiance apparente élevée puisque les intervalles se resserrent. Ce risque de fausse certitude est le principal danger opérationnel. Le projet vise à le caractériser et à construire un diagnostic permettant de le détecter avant estimation.

Le travail est mené sur deux terrains aux régimes de données opposés : la mesure de performance, avec peu d'observations et des transformations non linéaires, et la tarification assurantielle, avec beaucoup d'observations et une structure simple. La comparaison entre les deux valide la robustesse des conclusions.

Données du sujet :

Le projet repose sur des données simulées, nécessaires à l'évaluation puisque la mesure du gain de transfert exige de disposer des vraies valeurs des paramètres.

Deux processus générateurs sont utilisés.

Le premier reproduit un ensemble de jeux de données de mesure de performance : plusieurs dizaines de cas, chacun observé sur trois ans en fréquence hebdomadaire, avec trois à cinq leviers. Les paramètres propres à chaque cas sont

tirés d'une distribution commune, ce qui définit le lien entre cas et rend le transfert théoriquement possible. Un paramètre de dispersion contrôle l'hétérogénéité de la population et permet d'étudier le cas de nouveaux cas atypiques.

Le second reproduit un ensemble de portefeuilles d'assurance non-vie : plusieurs portefeuilles de tailles variées, avec pour chaque police une exposition, des variables tarifaires et un nombre de sinistres. La structure hiérarchique porte sur les niveaux de risque par portefeuille.

Le code de génération est fourni par l'encadrant. Une validation sur données réelles anonymisées pourra être envisagée en fin de projet sous réserve d'accord interne, mais n'est pas requise pour l'aboutissement du travail.

Modèles envisagés du sujet :

Deux familles de modèles sont mobilisées, correspondant aux deux terrains d'application.

Pour la mesure de performance, le modèle est une régression bayésienne hiérarchique à transformations non linéaires paramétriques, intégrant un effet de persistance temporelle et des rendements décroissants, avec une structure hiérarchique sur les coefficients d'efficacité.

Pour la tarification assurantielle, le modèle est un modèle linéaire généralisé hiérarchique de comptage, de spécification Poisson avec fonction de lien logarithmique et exposition en décalage, la hiérarchie portant sur les effets de portefeuille.

Dans les deux cas, l'inférence est conduite par Monte-Carlo hamiltonien (NUTS) sous PyMC, avec paramétrisation non centrée.

Le dispositif de meta-learning distingue une phase d'apprentissage, consistant à estimer la distribution a posteriori des hyperparamètres sur l'ensemble d'entraînement, et une phase d'adaptation, où cette distribution devient la loi a priori du cas test. Les stratégies de transfert comparées portent sur la quantité d'information propagée entre les deux phases.

Une comparaison avec l'estimateur de crédibilité de Bühlmann-Straub sera conduite sur le cas assurantiel, afin de situer l'approche par rapport à la pratique actuarielle établie.

Selon l'avancement, des approximations variationnelles pourront être explorées pour réduire le coût de la phase d'apprentissage lorsque le nombre de cas augmente.

Bibliographie du sujet :

A titre indicatif (les premiers papiers à lire seront sélectionnées ensemble avec les encadrants) :

Finn, C., Abbeel, P., Levine, S. (2017). Model-Agnostic Meta-Learning for Fast Adaptation of Deep Networks. *International Conference on Machine Learning*.

Grant, E., Finn, C., Levine, S., Darrell, T., Griffiths, T. (2018). Recasting Gradient-Based Meta-Learning as Hierarchical Bayes. *International Conference on Learning Representations*.

Amit, R., Meir, R. (2018). Meta-Learning by Adjusting Priors Based on Extended PAC-Bayes Theory. *International Conference on Machine Learning*.

Pentina, A., Lampert, C. H. (2014). A PAC-Bayesian Bound for Lifelong Learning. *International Conference on Machine Learning*.

Bühlmann, H. (1967). Experience rating and credibility. *ASTIN Bulletin*, 4(3), 199-207.

Bühlmann, H., Gisler, A. (2005). *A Course in Credibility Theory and its Applications*. Springer.

Gelman, A., Hill, J. (2006). *Data Analysis Using Regression and Multilevel/Hierarchical Models*. Cambridge University Press.

Gelman, A., Carlin, J. B., Stern, H. S., Dunson, D. B., Vehtari, A., Rubin, D. B. (2013). *Bayesian Data Analysis*, 3rd ed., chapitre 5. Chapman and Hall/CRC.

Betancourt, M., Girolami, M. (2015). Hamiltonian Monte Carlo for Hierarchical Models.

Ohlsson, E., Johansson, B. (2010). *Non-Life Insurance Pricing with Generalized Linear Models*. Springer.

Jin, Y., Wang, Y., Sun, Y., Chan, D., Koehler, J. (2017). Bayesian Methods for Media Mix Modeling with Carryover and Shape Effects. Google Research.

Notation du sujet :

Commentaires :