



SUJET STATAPP 348 - 2026-2027

Sujet proposé par : KORFED Marouan - korfed.marouan@gmail.com

Organisme : KORFED SAS

Catégorie : Actuariat

Sujet :

Modélisation et prédiction du risque auto : comparaison des méthodes actuarielles, du Machine Learning et de l'Intelligence Artificielle générative

Description du sujet :

PROBLÉMATIQUE

La tarification en assurance automobile repose notamment sur l'évaluation du risque associé à chaque assuré. Un enjeu central pour l'actuaire consiste à estimer, à partir des caractéristiques observables du contrat, de l'assuré et du véhicule, la fréquence attendue des sinistres ainsi que leur coût.

Traditionnellement, ces deux composantes sont modélisées à l'aide de méthodes statistiques telles que les modèles linéaires généralisés (GLM). Ces approches présentent notamment l'avantage d'être relativement interprétables et de permettre à l'actuaire d'identifier et de quantifier l'effet des différents facteurs de risque.

Le développement de la Data Science, plus particulièrement du Machine Learning, puis plus récemment des méthodes d'intelligence artificielle générative, offre de nouvelles possibilités pour la modélisation du risque assurantiel. Des algorithmes tels que le Gradient Boosting ou les réseaux de neurones peuvent notamment capturer des relations non linéaires et des interactions complexes entre les variables.

Ces nouvelles approches soulèvent cependant une question particulièrement importante dans un contexte actuariel : le recours à des modèles d'intelligence artificielle permet-il d'obtenir une amélioration suffisamment importante des prédictions pour justifier leur complexité et leur moindre interprétabilité ?

L'objectif du projet sera ainsi de construire et comparer plusieurs générations de modèles de prédiction du risque automobile :

Approches actuarielles traditionnelles, notamment les modèles linéaires généralisés ;

Méthodes de machine learning, telles que Random Forest et Gradient Boosting ;

Approches d'intelligence artificielle, notamment Deep Learning mais également des nouvelles solutions d'IA générative (ChatGPT, Claude, etc).

Les étudiants pourront étudier séparément deux composantes fondamentales du risque : la fréquence des sinistres et leur sévérité, avant de les combiner afin d'obtenir une estimation du coût attendu du risque.

La charge annuelle attendue d'un contrat pourra ainsi être estimée selon une approche de type fréquence $\times$ coût.

UN « BENCHMARK IA » APPLIQUÉ À L'ACTUARIAT

Une dimension spécifique du projet consistera à mettre en place un benchmark expérimental de différentes approches

d'intelligence artificielle sur une même problématique actuarielle.

L'objectif ne sera pas simplement de tester le plus grand nombre possible d'algorithmes, mais de déterminer dans quelles situations les méthodes les plus récentes apportent réellement une valeur supplémentaire par rapport aux outils traditionnellement utilisés en actuariat.

À données et échantillons de validation identiques, les étudiants pourront comparer plusieurs familles de modèles.

La comparaison pourra être effectuée selon plusieurs dimensions : performance prédictive, calibration, robustesse hors échantillon, stabilité, temps de calcul, complexité et interprétabilité des résultats.

Une attention particulière sera portée à l'explicabilité des modèles. Les étudiants pourront mobiliser des méthodes permettant d'identifier les variables déterminantes dans les prédictions et de comparer les facteurs de risque identifiés par les modèles traditionnels et par les modèles d'IA.

Le projet pourra ainsi chercher à déterminer si l'IA détecte des interactions ou des non-linéarités qui ne sont pas correctement capturées par une tarification actuarielle traditionnelle.

Données du sujet :

Les données utilisées seront des données anonymisées relatives à des contrats d'assurance automobile et aux sinistres associés.

Modèles envisagés du sujet :

Le projet pourra notamment mobiliser :

statistiques descriptives et visualisation ;
modèles linéaires généralisés ;
modèles de Poisson et binomial négatif ;
modèles Gamma et log-normaux ;
prise en compte de l'exposition au risque ;
Random Forest et Gradient Boosting ;
réseaux de neurones ;
IA générative ;
méthodes d'explicabilité des modèles ;
analyse de l'importance et de l'effet des variables ;
comparaison statistique des performances prédictives.

Bibliographie du sujet :

Partrat, C. & Besson, J.-L. ? Assurance non-vie : modélisation, simulation, Economica.

Charpentier, A. & Denuit, M. ? Mathématiques de l'assurance non-vie, Tome 1 : Principes fondamentaux de la théorie du risque, Economica.

Chanh, S. & Le Cheualier, E. ? Manuel de l'assurance automobile, L'Argus de l'assurance.

Institut des actuaires ? Mémoires d'actuariat, travaux et mémoires consacrés notamment à la tarification, à la modélisation des risques et aux applications de la Data Science en assurance non-vie.

Notation du sujet :

Commentaires :

Le sujet est adéquat aux attendus du Statapp. Je n'ai pas vu d'infos sur la disponibilité des données.