



SUJET STATAPP 288 - 2026-2027

Sujet proposé par : VIGNARD Alexis - alexis.vignard98@gmail.com

Organisme : Société Générale

Catégorie : Autre

Sujet :

L'incertitude des systèmes multi-agents

Description du sujet :

Les systèmes multi-agents fondés sur des Large Language Models (LLM) constituent aujourd'hui l'une des évolutions majeures de l'intelligence artificielle. Contrairement à un LLM classique qui génère uniquement du texte, ces systèmes reposent sur plusieurs agents spécialisés capables de collaborer, planifier, utiliser des outils et prendre des décisions successives afin de résoudre une tâche complexe. Des frameworks open source tels LangGraph permettent aujourd'hui de concevoir facilement ce type d'architectures multi-agents ; en représentant explicitement ces architectures sous forme de graphes d'états, dont les nœuds correspondent aux agents, aux outils ou aux validateurs et les transitions aux décisions prises

Cependant, une erreur commise lors d'une étape intermédiaire peut être propagée aux autres agents et conduire à l'échec de l'ensemble du workflow. Une question centrale émerge alors : comment estimer la confiance que l'on peut accorder aux décisions prises par un système multi-agents ?

L'objectif du projet sera donc d'effectuer :

- 1- une revue de littérature sur les méthodes de quantification de l'incertitude appliquées aux LLM, aux agents décisionnels et aux systèmes multi-agents ;
- 2- apprendre à manipuler des frameworks agentiques open source tels que LangGraph et construire une architecture simple composée de 2 à 3 agents collaboratifs ;
- 3- étudier des tâches nécessitant l'utilisation d'outils, la prise de décision et l'exécution d'actions dans un environnement contrôlé ;
- 4- implémenter différentes méthodes existantes de quantification, de calibration et de propagation de l'incertitude au niveau des agents, des actions et des trajectoires. L'évaluation distinguera les mesures de performance (taux de réussite, validité des appels d'outils), de calibration (Brier Score, log-loss, Expected Calibration Error), d'étude de distribution des scores modèles (entropie), de détection d'erreurs (AUROC, AUPRC) et d'abstention (courbes risque-couverture et AURC)
- 5- réaliser un benchmark comparatif permettant d'évaluer la capacité de ces méthodes à détecter les erreurs, anticiper l'échec d'une tâche et déclencher, lorsque cela est pertinent, une validation, une clarification ou une abstention.

Attention : ce sujet est certes porteur dans le domaine de l'IA, cependant, il reste dense et surtout difficile pour des étudiants de 2A. Ainsi, avant de candidater au sujet, il convient de s'assurer d'être motivé car il demandera de rapidement se familiariser avec les LLM, les systèmes multi-agents, les frameworks agentiques ainsi que les concepts de calibration et de quantification de l'incertitude.

Données du sujet :

Dans un premier temps, les étudiants devront identifier et déployer un environnement

d'évaluation adapté aux tâches étudiées. Contrairement aux benchmarks classiques de machine learning reposant uniquement sur des jeux de données, les benchmarks d'agents fournissent généralement un environnement complet comprenant des tâches, des outils, des données métier, des règles d'interaction et des mécanismes d'évaluation automatique :

? ToolSandbox : benchmark d'utilisation d'outils avec état, dépendances entre actions et évaluation de jalons intermédiaires et finaux.

? ?²-Bench : benchmark évaluant des agents interagissant avec des outils et un environnement dynamique à travers plusieurs étapes décisionnelles.

? AgentBench : benchmark d'évaluation des capacités de raisonnement, de décision et d'action des agents LLM ;

? MultiAgentBench : pour tester la coordination et la propagation entre agents.

Selon les ressources disponibles et la faisabilité technique, un sous-ensemble de ces benchmarks ou même un environnement simplifié pourra être retenu. D'autres environnements peuvent également être envisagés selon les propositions des étudiants.

Les tâches étudiées devront permettre d'évaluer des décisions observables et vérifiables. Une action ne devra pas être jugée uniquement par comparaison à une trace de référence unique - plusieurs trajectoires pouvant être valides, l'évaluation reposera notamment sur :

? la sélection de l'outil et la validité de ses paramètres ;

? le respect des préconditions et la transition d'état obtenue ;

? l'atteinte de jalons intermédiaires et la réussite finale de la tâche ;

? la décision d'agir, de demander une clarification ou de s'abstenir ;

? la correction ou la validation d'actions réalisées par d'autres agents.

Modèles envisagés du sujet :

Les agents devront être construits à l'aide de LangGraph et s'appuyer sur des modèles open source pré-entraînés ; ou via des modèles propriétaires si cela est possible.

Modèles envisageables selon les ressources accessibles aux étudiants via Onyxia : - - -

Petits modèles : Qwen2.5-3B-Instruct ; Phi-3.5-mini.

Modèles « moyens » : Qwen2.5-7B-Instruct ; Llama-3.1-8B-Instruct.

Modèle propriétaire de pointe (via clef API avec nombre limité de requête journalières) : Gemini 2.0 Flash

Une architecture typique pourra par exemple reposer sur :

? un agent de planification (Planner), qui propose une action ;

? un agent d'exécution (Executor), qui interagit avec l'environnement ;

? un agent de contrôle (Reviewer), qui évalue l'action et peut la valider, demander une clarification ou déclencher une abstention

Extension possible du sujet :

Selon le niveau d'avancement du projet, une extension est possible sur l'explicabilité des décisions des systèmes multi-agents.

Bibliographie du sujet :

1- Uncertainty Quantification in LLM Agents: Foundations, Emerging Challenges, and Opportunities (Oh et al., ACL 2026)

2- Towards Uncertainty-Aware Language Agent (Han et al., Findings of ACL 2024)

3- Uncertainty Calibration for Tool-Using Language Agents (Liu et al., Findings of EMNLP 2024)

4- Robots That Ask for Help: Uncertainty Alignment for Large Language Model Planners (Ren et al., CoRL 2023)

5- Structured Uncertainty Guided Clarification for LLM Agents (Suri et al., Findings of ACL

2026)

6- Uncertainty Propagation on LLM Agent (Zhao et al., ACL 2025)

7- UProp: Investigating the Uncertainty Propagation of LLMs in Multi-Step Agentic Decision Making (Duan et al., 2025)

8- PropUQ-MAS: Propagation-Aware Uncertainty Quantification for LLM Multi-Agent Systems (Liu et al., EMNLP 2026)

9- $\mathcal{U}^2$ -Bench: Evaluating Conversational Agents in a Dual-Control Environment (Barres et al., ICML 2026)

10- ToolSandbox: A Stateful, Conversational, Interactive Evaluation Benchmark for LLM Tool Use Capabilities (Lu et al., 2024)

11- AgentBench: Evaluating LLMs as Agents (Liu et al. ICLR 2024)

12- MultiAgentBench: Evaluating the Collaboration and Competition of LLM Agents (Zhu et al. ACL 2025)

Notation du sujet :

2

Commentaires :

Sujet intéressant mais très déconseillé: le gros du travail nécessite une compréhension et une maîtrise de ce qu'est un LLM (programme de fin de 3A) et utilise assez peu la formation ENSAE 1A-2A. Le sujet semble être un programme de recherche de thèse, pas un stat-app.