



SUJET STATAPP 295 - 2026-2027

Sujet proposé par : MEREAU Julien - j.mereau@quant-cube.com
Organisme : QuantCube Technology
Catégorie : Macroéconomie, Economie Monétaire
Sujet :
Nowcasting des Nonfarm Payrolls américains à partir de données alternatives haute fréquence

Description du sujet :

Les Nonfarm Payrolls (NFP), publiés chaque mois par le Bureau of Labor Statistics (BLS) dans le rapport Employment Situation, mesurent la variation du nombre d'emplois salariés non agricoles aux Etats-Unis. Chaque mois, l'enquête Current Employment Statistics (CES) qui les produit interroge environ 119 000 entreprises et administrations, représentant près de 622 000 sites, et le NFP est devenu l'un des indicateurs macroéconomiques les plus suivis par les marchés financiers, la publication du premier vendredi du mois étant systématiquement associée à des mouvements marqués du dollar, des taux et des indices actions.

Ce suivi intense se heurte pourtant aux limites structurelles d'une statistique d'enquête : le chiffre publié n'est qu'une estimation provisoire, révisée deux fois au cours des deux mois suivants à mesure que de nouveaux retours d'entreprises parviennent au BLS, puis ajustée une nouvelle fois lors du rebenchmark annuel réalisé à partir des données administratives de l'assurance chômage (QCEW) ? une révision dont l'amplitude moyenne absolue a atteint 0,2 % de l'emploi total sur les dix dernières années, avec des écarts allant jusqu'à 0,4 %. Entre deux publications mensuelles, les acteurs de marché doivent donc composer avec un mois entier d'incertitude sur l'état réel du marché du travail américain. Contrairement à des données de consommation où l'enjeu est principalement un problème de délai de publication, l'emploi combine un stock (le niveau d'emploi) et un flux (les créations nettes du mois), observés à des fréquences hétérogènes selon la source alternative mobilisée ? quotidienne pour la fréquentation des commerces, hebdomadaire pour les offres d'emploi ? ce qui pose un véritable problème d'estimation à fréquences mixtes, et non un simple enjeu de disponibilité des données.

Ainsi, le problème central est le suivant : comment construire, à partir de données alternatives à haute fréquence (offres d'emploi en ligne, tendances de recherche, fréquentation physique des commerces), un indicateur capable d'anticiper, avant la publication officielle du BLS, l'évolution mensuelle des Nonfarm Payrolls aux Etats-Unis ?

Le projet visera à construire un tel indicateur en confrontant deux familles d'approches ? modèles économétriques de séries temporelles et modèles de machine learning ? et à évaluer leur capacité prédictive hors échantillon, en conditions de pseudo temps réel, par comparaison au consensus des économistes professionnels.

Données du sujet :

Données macroéconomiques officielles

Nonfarm Payrolls, variable cible (Bureau of Labor Statistics, enquête CES)

Initial et continuing jobless claims, hebdomadaires (Department of Labor, ETA)

Offres d'emploi, embauches et séparations ? JOLTS (Bureau of Labor Statistics)

Données alternatives à haute fréquence (QuantCube)

Offres d'emploi en ligne : nombre d'offres actives et nombre de nouvelles offres publiées

Tendances de recherche (Google Trends) sur des requêtes liées à l'emploi et à la recherche d'emploi

Données de fréquentation physique (foot traffic) des commerces et lieux d'activité

Données météorologiques, notamment pour capter l'impact de grands événements (tempêtes, ouragans) sur l'activité et l'emploi

et d'autres données si celles-ci sont jugées pertinentes.

Modèles envisagés du sujet :

Du côté économétrique, des modèles autorégressifs (SARIMAX, VAR) permettront de capter la dynamique propre du NFP et les effets calendaires/saisonniers. Pour intégrer des séries observées à des fréquences hétérogènes ? quotidienne pour la fréquentation des commerces et les tendances de recherche, hebdomadaire pour les offres d'emploi et les jobless claims, mensuelle pour la cible ? le projet mobilisera des modèles à facteurs dynamiques (DFM) et des modèles à état caché (représentation espace-état, filtre de Kalman), en les situant par rapport aux alternatives de type MIDAS et bridge equations.

Du côté machine learning, des régressions linéaires avec et sans pénalisation (Lasso, Ridge) permettront d'arbitrer entre un grand nombre de variables candidates issues des données alternatives tout en limitant le risque de surapprentissage sur un historique mensuel nécessairement court. Les modèles seront évalués en conditions de pseudo temps réel (fenêtre glissante ou expansive), en les comparant au consensus des économistes professionnels.

Bibliographie du sujet :

Bok, B., Caratelli, D., Giannone, D., Sbordone, A. M., & Tambalotti, A. (2018). "Macroeconomic Nowcasting and Forecasting with Big Data." *Annual Review of Economics*, 10, 615-643.

Bhatia, T. (2020). "Predicting Non Farm Employment." arXiv:2009.14282.

Borup, D., & Schütte, E. C. M. (2022). "In Search of a Job: Forecasting Employment Growth Using Google Trends." *Journal of Business & Economic Statistics*, 40(1), 186-200.

Ótiefánik, M., Lyócsa, ?, & Bilka, M. (2023). "Using Online Job Postings to Predict Key Labour Market Indicators." *Social Science Computer Review*, 41(5), 1630-1649.

Füleký, P., & Szapudi, I. (2022). "Bird's Eye View of COVID-19, Mobility, and Labor Market Outcomes Across the US." *Economics of Disasters and Climate Change*, 6(2), 339-353.

Lengerich, B. (2023). "Are ADP and NFP Employment Numbers Correlated? Employment Numbers: ADP, NFP, Outliers, and Context-Specific Correlation." *Medium*, 15 juillet 2023.

Notation du sujet :

Commentaires :