



SUJET STATAPP 308 - 2026-2027

Sujet proposé par : HU François - francois.hu@ekimetrics.com

Organisme : Ekimetrics

Catégorie : Marketing Quantitatif

Sujet :

Sensibilité au choix des lois a priori dans les modèles bayésiens hiérarchiques : effets sur l'estimation et sur la décision

Description du sujet :

Les modèles bayésiens hiérarchiques appliqués à la mesure d'efficacité reposent sur un nombre important d'hypothèses a priori : lois de distribution sur l'efficacité de chaque levier, sur la persistance temporelle des effets, et sur le point de saturation au-delà duquel un investissement supplémentaire devient improductif. Le contexte est structurellement défavorable : on dispose typiquement de trois années d'historique hebdomadaire, soit environ 150 observations, pour estimer plusieurs dizaines de paramètres. Les lois a priori jouent donc un rôle déterminant.

La littérature récente propose des outils pour diagnostiquer cette dépendance. La méthode de power-scaling développée par Kallioinen et al. (2023) perturbe la loi a priori en l'élevant à une puissance variable et mesure, par échantillonnage préférentiel, le déplacement induit sur la loi a posteriori. Cette approche est implémentée dans le package R `priorsense` et s'est imposée comme la référence du domaine.

Ces diagnostics présentent toutefois une limite conceptuelle. Ils quantifient la sensibilité au niveau des paramètres du modèle. Or l'usage réel de ces modèles n'est pas l'estimation de paramètres mais la prise de décision : le modèle alimente un problème d'optimisation sous contrainte budgétaire, dont la solution est une allocation de ressources. Rien ne garantit que la sensibilité au niveau des paramètres se transmette proportionnellement à la sensibilité au niveau de la décision.

Le projet propose de tester cette dissociation. L'intuition repose sur la structure du problème d'optimisation : à l'optimum, les conditions du premier ordre égalisent les rendements marginaux entre leviers, de sorte que la décision ne dépend pas des paramètres pris séparément mais d'une quantité composite. Il existe donc des directions de perturbation qui déplacent fortement les paramètres sans modifier l'allocation, et inversement. Si cette dissociation est établie empiriquement, elle implique que les diagnostics actuels mesurent une quantité qui n'est pas celle qui engage les décisions.

Le travail comporte trois volets. Le premier consiste à porter la méthode de power-scaling vers l'écosystème Python (PyMC), pour lequel aucune implémentation n'existe, en validant les résultats contre la version R. Le deuxième étend la mesure de sensibilité aux quantités décisionnelles, ce qui nécessite de définir des métriques appropriées : distance entre allocations, changement d'ordonnancement des leviers, et regret décisionnel mesurant la perte encourue en optimisant sous une hypothèse a priori erronée. Le troisième caractérise empiriquement les conditions d'apparition de la dissociation, en faisant varier le régime de données, le nombre de leviers et l'intensité du partage hiérarchique.

Données du sujet :

Le projet s'appuie principalement sur des données simulées, ce qui constitue une nécessité méthodologique plutôt qu'une limitation : la mesure du regret décisionnel exige de connaître les vraies valeurs des paramètres, information indisponible sur données réelles.

Le processus générateur reproduit la structure d'un jeu de données MMM industriel : séries hebdomadaires sur trois ans, trois à huit canaux publicitaires, transformations non linéaires d'effet mémoire (adstock géométrique) et de rendements décroissants (fonction de Hill), saisonnalité, variables de contrôle. Les paramètres sont tirés d'une structure hiérarchique multi-marchés. Le code de génération et les paramètres de référence sont fournis par l'encadrant.

Une validation sur données réelles anonymisées d'Ekimetrics pourra être envisagée en fin de projet, sous réserve d'accord interne. Ces données couvriraient plusieurs marchés géographiques et permettraient de vérifier que les phénomènes observés en simulation ne sont pas des artefacts du processus générateur. Cette étape n'est pas critique pour l'aboutissement du projet.

Modèles envisagés du sujet :

Le modèle de base est une régression bayésienne hiérarchique à transformations non linéaires paramétriques.

L'inférence est conduite par méthode de Monte-Carlo hamiltonienne (NUTS) sous PyMC, avec paramétrisation non centrée pour éviter les pathologies géométriques classiques des modèles hiérarchiques.

L'analyse de sensibilité repose sur le power-scaling par échantillonnage préférentiel lissé (PSIS), qui évite de réestimer le modèle pour chaque perturbation de la loi a priori.

La composante décisionnelle mobilise un problème d'optimisation non linéaire sous contrainte budgétaire, résolu par programmation séquentielle quadratique ou algorithme évolutionnaire selon la taille du problème.

Les modèles de comparaison incluent les implémentations open-source de référence (`PyMC-Marketing` et `Meridian` (Google)) afin de situer les résultats par rapport à l'état de la pratique.

Bibliographie du sujet :

Les trois premiers articles sont les plus importants

Analyse de sensibilité bayésienne

- Kallioinen, N., Paananen, T., Bürkner, P.-C., Vehtari, A. (2023). Detecting and diagnosing prior and likelihood sensitivity with power-scaling. **Statistics and Computing**, 34(1).
- Roos, M., Martins, T. G., Held, L., Rue, H. (2015). Sensitivity Analysis for Bayesian Hierarchical Models. **Bayesian Analysis**, 10(2), 321?349.
- Vehtari, A., Simpson, D., Gelman, A., Yao, Y., Gabry, J. (2024). Pareto Smoothed Importance Sampling. **Journal of Machine Learning Research**.

Modélisation marketing bayésienne

- Jin, Y., Wang, Y., Sun, Y., Chan, D., Koehler, J. (2017). Bayesian Methods for Media Mix Modeling with Carryover and Shape Effects. Google Research.
- Chan, D., Perry, M. (2017). Challenges and Opportunities in Media Mix Modeling. Google Research.
- Zhang, Y. et al. (2024). Media Mix Model Calibration With Bayesian Priors. Google Research.

Modèles hiérarchiques et inférence

- Betancourt, M., Girolami, M. (2015). Hamiltonian Monte Carlo for Hierarchical Models. In **Current Trends in Bayesian Methodology with Applications**, Chapman and Hall/CRC.
- Gelman, A., Carlin, J. B., Stern, H. S., Dunson, D. B., Vehtari, A., Rubin, D. B. (2013). **Bayesian Data Analysis**, 3rd ed., chapitre 5.

- Gelman, A. et al. (2020). Bayesian Workflow. *arXiv:2011.01808*.

Décision sous incertitude

- Berger, J. O. (1985). *Statistical Decision Theory and Bayesian Analysis*. Springer.
- Neiswanger, W., Yu, L., Zhao, S., Meng, C., Ermon, S. (2022). Generalizing Bayesian Optimization with Decision-theoretic Entropies. *NeurIPS*.

Notation du sujet :

Commentaires :