



SUJET STATAPP 301 - 2026-2027

Sujet proposé par : CARRIE Hugo - hugo.carrie@withings.com

Organisme : Withings SAS

Catégorie : Marketing Quantitatif

Sujet :

Souscription et résiliation d'un abonnement de santé connectée : détecter les signaux d'usage précurseurs et identifier les leviers d'action

Description du sujet :

Withings commercialise un abonnement, Withings+, qui donne accès à des analyses approfondies et à des programmes de santé au sein de son application mobile. Cet abonnement est un levier de croissance central pour l'entreprise : il transforme une vente de matériel ponctuelle en revenu récurrent, et sa performance se joue sur deux fronts symétriques, convertir les possesseurs d'appareils en abonnés et retenir les abonnés existants.

Ces deux événements, la souscription et la résiliation, ne sont aujourd'hui observés qu'une fois survenus. Ils sont pourtant vraisemblablement précédés de plusieurs semaines de signaux comportementaux : intensification ou raréfaction de la prise de mesures, perte de régularité, abandon de certaines fonctionnalités, exploration de contenus réservés aux abonnés, ajout ou retrait d'un appareil. L'objet du projet est d'établir si ces signaux existent, de les caractériser, et de déterminer à quel horizon et avec quelle fiabilité ils permettent d'anticiper l'événement.

Le sujet comporte deux volets. Le premier est descriptif et prédictif : quels comportements précèdent une souscription, lesquels précèdent une résiliation, et dans quelle mesure ces événements sont-ils prévisibles ? Le second est décisionnel : parmi ces signaux, lesquels peuvent être déclenchés, accélérés ou interrompus par une action de l'entreprise ? Un déterminant fortement prédictif n'est pas nécessairement un levier, et cette distinction entre prédiction et effet d'une intervention fait la valeur opérationnelle du travail.

Plusieurs difficultés méthodologiques structurent le projet. Les données brutes sont des flux d'événements horodatés et irréguliers, dont la transformation en variables exploitables (intensité, régularité, tendance, ruptures) constitue en soi un travail de modélisation. La résiliation est un délai avant événement soumis à censure à droite : les abonnés encore actifs à la date d'extraction n'ont pas renoncé à partir, ils ne sont simplement pas encore partis, et les traiter comme des non-événements biaise l'estimation. Les comportements évoluent pendant la durée de vie de l'abonnement, ce qui impose des covariables variant dans le temps. Enfin, les taux d'événement mensuels sont de l'ordre de quelques pourcents, ce qui disqualifie les métriques usuelles de classification et impose une validation hors-temps, par entraînement sur les cohortes anciennes et test sur les cohortes récentes, compte tenu des effets de cohorte, de saisonnalité et d'évolution du produit.

Les enjeux sont directement financiers : l'abonnement représente une part significative et croissante du revenu récurrent de l'entreprise, et quelques points de rétention mensuelle modifient sensiblement la valeur vie client, donc les budgets d'acquisition soutenables.

Les élèves devront maîtriser Python (pandas, scikit-learn) ainsi que les logiciels bureautiques standards (LaTeX, Pack Office). Une familiarité avec SQL est un plus, mais n'est pas requise.

Données du sujet :

Une extraction pseudonymisée sera mise à disposition, portant sur une cohorte de plusieurs centaines de milliers

d'utilisateurs observés sur vingt-quatre à trente-six mois.

Référentiel utilisateur : date de création du compte, pays, langue, canal d'acquisition, caractéristiques déclarées et discrétisées.

Parc d'appareils : types d'appareils détenus, dates d'activation, ajouts et retraits successifs.

Événements de mesure : horodatage et type de mesure par appareil. Conformément au RGPD, aucune donnée de santé n'est transmise : seul l'acte de mesure est observé, jamais sa valeur.

Événements applicatifs : sessions, écrans consultés, fonctionnalités utilisées, notifications reçues et ouvertes.

Cycle de vie de l'abonnement : entrée en essai, souscription payante, formule et prix payé, renouvellements, date de résiliation, motif auto-déclaré lorsqu'il est collecté, éventuel réabonnement.

Exposition marketing : campagnes relationnelles reçues et promotions appliquées.

Modèles envisagés du sujet :

L'articulation ci-dessous est indicative et sera discutée en début de projet. Elle propose une progression en trois temps, du plus interprétable au plus décisionnel, chaque étape restant utile même si la suivante n'aboutit pas.

Caractériser les signaux. Après une description des courbes de rétention par cohorte, un modèle de durée est estimé sur les deux événements. Le modèle de Cox, ou sa version en temps discret estimée sur un panel utilisateur fois mois, exprime le risque de survenue de l'événement comme un multiplicateur appliqué à chaque comportement observé. La sortie est une grille de lecture directement interprétable et un niveau de risque par utilisateur, réactualisé à chaque période. L'hypothèse de proportionnalité des risques devra être explicitement testée et discutée : il est plausible qu'un signal soit discriminant en début de vie de l'abonnement et cesse de l'être ensuite.

Mesurer jusqu'où le phénomène est prévisible. Des méthodes d'apprentissage supervisé, forêts aléatoires et gradient boosting, sont ensuite appliquées aux mêmes données. Elles capturent des effets d'interaction que le modèle linéaire manque, au prix d'une lisibilité moindre, que l'on restaure par des mesures d'importance et des effets partiels. L'apport attendu est double : un score de ciblage plus performant, et surtout une borne sur la prévisibilité du phénomène. Si la performance plafonne à un niveau médiocre, le résultat est en soi informatif, puisqu'il indique que la décision d'abonnement ou de résiliation se joue largement en dehors du signal d'usage.

Estimer l'effet d'une action. Les deux premières étapes identifient qui est à risque, non qui est influençable. En s'appuyant sur l'historique d'exposition aux campagnes relationnelles, la dernière étape compare les utilisateurs exposés à des utilisateurs comparables non exposés, afin d'estimer non plus la probabilité de l'événement mais l'effet incrémental de l'intervention. La question devient : sur quel segment une action change-t-elle effectivement l'issue ? Cette étape exige une attention particulière aux conditions d'identification, les campagnes passées n'ayant pas été assignées aléatoirement ; les biais de sélection devront être traités et leurs limites explicitées.

Bibliographie du sujet :

Modélisation de la durée

Cox D. R. (1972), Regression Models and Life-Tables, Journal of the Royal Statistical Society Series B, 34(2). Singer J., Willett J. (1993), It's About Time: Using Discrete-Time Survival Analysis to Study Duration and the Timing of Events, Journal of Educational Statistics, 18(2). Fader P., Hardie B. (2007), How to Project Customer Retention, Journal of Interactive Marketing, 21(1).

Prédiction du churn

Neslin S., Gupta S., Kamakura W., Lu J., Mason C. (2006), Defection Detection: Measuring and Understanding the Predictive Accuracy of Customer Churn Models, *Journal of Marketing Research*, 43(2). Lemmens A., Croux C. (2006), Bagging and Boosting Classification Trees to Predict Churn, *Journal of Marketing Research*, 43(2). Breiman L. (2001), Random Forests, *Machine Learning*, 45(1).

Du score à l'action

Ascarza E. (2018), Retention Futility: Targeting High-Risk Customers Might Be Ineffective, *Journal of Marketing Research*, 55(1). Lemmens A., Gupta S. (2020), Managing Churn to Maximize Profits, *Marketing Science*, 39(5). Gutierrez P., Gerardy J.-Y. (2017), Causal Inference and Uplift Modelling: A Review of the Literature, *Proceedings of Machine Learning Research*, 67.

Notation du sujet :

Commentaires :