



SUJET STATAPP 345 - 2026-2027

Sujet proposé par : iakimova luliia - iakimova.ju@gmail.com

Organisme : N/A (Application non lié à l'entreprise)

Catégorie : Traitement du signal / NLP

Sujet :

Rapprochement automatique d'adresses d'entreprises avec la Base Adresse Nationale

Description du sujet :

Les adresses saisies dans le répertoire Sirene peuvent présenter de nombreuses variations d'écriture : abréviations, différences orthographiques, ponctuation ou formats différents. L'objectif du projet est d'étudier comment identifier automatiquement l'adresse officielle correspondante dans la Base Adresse Nationale.

À partir d'un échantillon d'établissements parisiens et du référentiel des adresses officielles de Paris, les étudiants compareront différentes approches de rapprochement, allant des méthodes de similarité entre chaînes de caractères aux méthodes de machine learning. Ils étudieront notamment la construction d'un score de correspondance, le choix du seuil de décision et le compromis entre faux positifs et faux négatifs.

Le projet pourra ensuite étudier la robustesse et la généralisation des méthodes à d'autres territoires.

Données du sujet :

Un échantillon de 5 000 établissements actifs de Paris, issu du fichier Sirene au 1er septembre 2026, sera fourni aux étudiants avec leurs adresses saisies.

Il sera complété par la Base Adresse Nationale, comprenant 152 628 adresses officielles de Paris avec leurs coordonnées géographiques.

Les deux sources sont publiques et librement accessibles et ne nécessitent pas de clé API. Les données sont déjà disponibles pour démarrer le projet.

Modèles envisagés du sujet :

Normalisation des adresses, distances et mesures de similarité entre chaînes, méthodes phonétiques, record linkage probabiliste et modèles supervisés de machine learning. Les performances seront évaluées notamment à l'aide de la précision, du rappel et du F1 score, avec une analyse des erreurs et du seuil de décision.

Bibliographie du sujet :

Christen P. (2012), Data Matching: Concepts and Techniques for Record Linkage, Entity Resolution, and Duplicate Detection, Springer.

Winkler W. E. (1990), String Comparator Metrics and Enhanced Decision Rules in the Fellegi-Sunter Model of Record Linkage.

INSEE, Répertoire Sirene.

Base Adresse Nationale, adresse.data.gouv.fr.

Notation du sujet :

2

Commentaires :

Le sujet est convaincant et sans doute "le moins impossible" de la classe des sujets NLP mais il consiste en l'utilisation de modèle de niveau fin de 3A. Il me semble "borderline"