



SUJET STATAPP 343 - 2026-2027

Sujet proposé par : NOËL Valentin - valentin.noel@devoteam.com

Organisme : Devoteam SAS

Catégorie : Traitement du signal / NLP

Sujet :

Une hallucination a-t-elle une forme ? Géométrie interne des représentations et détection des erreurs des modèles de langage

Description du sujet :

Quand un modèle de langage se trompe, il le fait avec la même assurance que lorsqu'il a raison. Les signaux de surface, probabilité des mots produits, entropie de la distribution de sortie, sont peu fiables : un modèle peut être très confiant et parfaitement faux.

L'hypothèse du sujet est que l'information se trouve ailleurs, plus tôt. Avant de produire un mot, le modèle construit une représentation interne : un point dans un espace de plusieurs centaines ou milliers de dimensions, et un graphe d'attention reliant les éléments du contexte. Ces objets ont une géométrie, et cette géométrie est mesurable. Dimension intrinsèque du nuage de représentations, rang effectif, trajectoire suivie au fil des couches, entropie spectrale et énergie haute fréquence du graphe d'attention, connectivité algébrique. Autant de descripteurs calculables, dont on peut tester s'ils portent l'information que la réponse en cours de formation est fausse.

La question centrale n'est pas de savoir si ces descripteurs sont corrélés à l'erreur : ils le seront. Elle est plus exigeante, et c'est ce qui fait tout l'intérêt statistique du sujet.

Apportent-ils quelque chose une fois contrôlés les signaux de sortie déjà disponibles gratuitement ?

C'est une comparaison de modèles emboîtés, et elle admet une réponse négative. Un mémoire concluant que la géométrie interne n'ajoute rien, démonstration à l'appui, serait un excellent mémoire et un résultat que la littérature actuelle ne fournit pas.

Questions proposées :

Caractériser la géométrie des représentations : estimation de la dimension intrinsèque (estimateurs de Levina-Bickel, méthode des deux plus proches voisins), rang effectif, ratio de participation, et leur évolution couche par couche. Cette structure se distingue-t-elle de celle d'une matrice aléatoire de mêmes dimensions, au sens de la loi de Marchenko-Pastur ?

Pouvoir discriminant individuel de chaque descripteur : courbes ROC, aire sous la courbe, intervalles de confiance. Avec plusieurs dizaines de descripteurs sur plusieurs dizaines de couches, le problème des tests multiples est réel et doit être traité.

Apport marginal. Modèle de référence fondé sur les seuls signaux de sortie, puis modèle enrichi par les descripteurs géométriques. Comparaison par tests de courbes ROC corrélées, gain d'aire sous la courbe, validation croisée par question pour éviter toute fuite d'information.

Transfert. Un détecteur appris sur un modèle fonctionne-t-il sur un autre, de taille ou de famille différente ? Les couches se correspondent-elles ? C'est la question qui décide si ces diagnostics ont une valeur pratique ou seulement descriptive.

Décision opérationnelle. Courbes risque-couverture : si l'on refuse de répondre lorsque l'indicateur dépasse un seuil, combien de bonnes réponses sacrifie-t-on pour chaque erreur évitée ?

Les élèves manipuleront des données inhabituelles, en grande dimension, avec une structure hiérarchique (question, couche, modèle) imposant de vrais choix de modélisation, et une question dont la réponse n'est pas connue à l'avance.

Données du sujet :

Le groupe produit lui-même ses données, à partir de ressources entièrement publiques, sur un ordinateur portable.

Jeux de questions et réponses factuelles avec étiquettes vrai ou faux, en accès libre : TriviaQA, Natural Questions, SciQ, FEVER, TruthfulQA, HaluEval, ainsi que les jeux d'énoncés vrais et faux publiés avec les travaux d'Azaria et Mitchell.

Modèles à poids ouverts de petite taille, exécutables sans matériel spécialisé : GPT-2, Pythia (160M à 1,4B), SmolLM2 (360M à 1,7B), Qwen2.5 (0,5B et 1,5B), Llama 3.2 1B. Les états cachés et les matrices d'attention s'extraient directement avec la bibliothèque Transformers, sur quelques milliers de questions courtes, en quelques heures de calcul sur un processeur ordinaire, ou en quelques minutes sur les ressources gratuites de type Colab.

Une propriété commode : ces petits modèles se trompent souvent, ce qui donne des classes bien équilibrées et évite le problème des événements rares qui pénaliseraient la même étude sur un modèle de grande taille.

L'encadrement fournit un notebook de démarrage montrant comment extraire états cachés et cartes d'attention et calculer les premiers descripteurs, afin que le groupe soit productif dès la deuxième séance. Aucune donnée n'est confiée par l'entreprise.

Modèles envisagés du sujet :

Estimation de dimension intrinsèque (Levina-Bickel), rang effectif, ratio de participation. Analyse spectrale de matrices : décomposition en valeurs singulières, loi de Marchenko-Pastur comme référence de bruit, statistique de Tracy-Widom pour la valeur propre maximale. Analyse spectrale de graphes : Laplacien normalisé du graphe d'attention, transformée de Fourier sur graphe, entropie spectrale, énergie haute fréquence, connectivité algébrique.

Détection et comparaison : courbes ROC, test de DeLong pour courbes corrélées, régression logistique à effets mixtes avec effets aléatoires par question, comparaison de modèles emboîtés, sélection de variables régularisée (lasso, elastic net) en grande dimension, contrôle du taux de fausses découvertes (Benjamini-Hochberg) sur les couches et les descripteurs, validation croisée par groupes, courbes risque-couverture.

Logiciel au choix du groupe : Python (transformers, numpy, scikit-learn, statsmodels, networkx) ou R pour la partie statistique après extraction.

Bibliographie du sujet :

Noël, V., Srinivasan, B., Healy, K. et Madathil, V. (2026), Does the Optimal Hallucination Detector for Agentic Tool Calls Depend on Model Scale ?, 2nd Agents in the Wild Workshop, ICML 2026. Code : github.com/vcnoel/spectral-tool-use.

Healy, K., Srinivasan, B., Madathil, V. et Wu, J. (2026), Internal Representations as Indicators of Hallucinations in Agent Tool Selection, arXiv:2601.05214.

Noël, V. (2025), A Graph Signal Processing Framework for Hallucination Detection in Large Language Models, arXiv:2510.19117.

Noël, V. (2026), Geometry of Reason : Spectral Signatures of Valid Mathematical Reasoning, ICML 2026.

Binkowski, J., Janiak, D., Sawczyn, A., Gabrys, B. et Kajdanowicz, T. (2025), Hallucination Detection in LLMs Using Spectral Features of Attention Maps, EMNLP 2025.

Li, J., Tu, G. et Hu, J. (2025), LLM Hallucination Detection : HSAD, arXiv:2509.23580.

Badash, Z. N., Belinkov, Y. et Freiman, M. (2026), Between the Layers Lies the Truth : Uncertainty Estimation in LLMs Using Intra-Layer Local Information Scores, arXiv:2603.22299.

Chen, C., Liu, K., Chen, Z. et al. (2024), INSIDE : LLMs' Internal States Retain the Power of Hallucination Detection, arXiv:2402.03744.

DeLong, E. R., DeLong, D. M. et Clarke-Pearson, D. L. (1988), Comparing the Areas Under Two or More Correlated Receiver Operating Characteristic Curves, Biometrics.

Hanley, J. A. et McNeil, B. J. (1982), The Meaning and Use of the Area Under a Receiver Operating Characteristic Curve, Radiology.

Obuchowski, N. A. et McClish, D. K. (1997), Sample Size Determination for Diagnostic Accuracy Studies Involving Binormal ROC Curve Indices, Statistics in Medicine.

Demsar, J. (2006), Statistical Comparisons of Classifiers over Multiple Data Sets, JMLR.

Vickers, A. J. et Elkin, E. B. (2006), Decision Curve Analysis, Medical Decision Making.

Shuman, D. I., Narang, S. K., Frossard, P., Ortega, A. et Vandergheynst, P. (2013), The Emerging Field of Signal Processing on Graphs, IEEE Signal Processing Magazine.

Patil, S. G., Mao, H., Yan, F. et al. (2025), The Berkeley Function Calling Leaderboard : From Tool Use to Agentic Evaluation of Large Language Models, ICML 2025.

Notation du sujet :

2

Commentaires :

Sujet merveilleux mais d'une difficulté théorique énorme qui me semble être plutôt d'un niveau thèse. La géométrie est hors champ ENSAE, les LLMs sont vus en fin de 3A, quant aux graphes d'attention... il me semble que ça s'adresse plus à un diplômé du MVA