



SUJET STATAPP 357 - 2026-2027



Sujet proposé par : Saada david - David@dataistudio.com

Organisme : Dstudio

Catégorie : Prédiction

Sujet :

Multimodal Buying Intent Prediction with Survival Analysis, Graph Learning & Learning-to-Rank

Description du sujet :

L'objectif du projet est de développer un moteur statistique capable d'identifier et de classer les entreprises présentant une forte probabilité d'achat à court terme de prestations Data et Intelligence Artificielle.

Le projet exploitera des signaux faibles observables avant l'expression explicite d'un besoin : recrutements Data/IA, nominations de dirigeants, appels d'offres, annonces de transformation, investissements technologiques, partenariats cloud/IA, publications institutionnelles ou évolutions organisationnelles.

Pour chaque entreprise observée à une date donnée, l'objectif sera d'estimer la probabilité d'apparition d'une opportunité commerciale à différents horizons temporels (30, 90 et 180 jours), ainsi que la nature probable du besoin : Data Platform, Analytics, Machine Learning, GenAI, gouvernance ou formation.

Le problème présente plusieurs difficultés statistiques : rareté des événements positifs, labels partiellement observés, censure temporelle, hétérogénéité des données structurées et textuelles, dérive temporelle et biais de sélection lié aux actions commerciales passées.

Le livrable final prendra la forme d'un moteur de ranking permettant de produire périodiquement une liste de comptes prioritaires, accompagnée d'une probabilité d'opportunité, d'un horizon temporel, d'un type de besoin probable et des principaux signaux explicatifs.

Données du sujet :

Le projet reposera sur la constitution d'un panel longitudinal d'entreprises françaises et européennes.

Les données pourront notamment inclure :

- offres d'emploi et dynamique des recrutements Data/IA ;
- appels d'offres et consultations publiques ;
- communiqués de presse et actualités d'entreprises ;
- rapports annuels et documents institutionnels ;
- nominations de dirigeants et évolutions organisationnelles ;
- annonces de partenariats technologiques, cloud ou IA ;
- données sectorielles et financières publiques ;
- contenus textuels publics associés aux entreprises ;
- historique daté des différents signaux observés ;
- données commerciales internes anonymisées lorsqu'elles sont disponibles : prises de contact, rendez-vous, opportunités et conversions.

Les données seront structurées sous forme d'un panel entreprise × temps permettant de reconstruire l'évolution des

signaux précédant l'apparition éventuelle d'une opportunité commerciale.

Une attention particulière sera portée à la construction des labels, au traitement des données manquantes et à la séparation temporelle entre données d'apprentissage et données de validation.

Modèles envisagés du sujet :

Plusieurs familles de modèles seront étudiées et comparées.

1. Modélisation de labels incomplets :

Positive-Unlabeled Learning, weak supervision et méthodes semi-supervisées.

2. Modélisation temporelle de l'apparition d'une opportunité :

modèles de Cox, modèles paramétriques de survie, Random Survival Forest, Gradient Boosting Survival, DeepSurv et modèles de competing risks pour distinguer plusieurs catégories de besoins.

3. Détection de ruptures et de signaux faibles :

CUSUM, Bayesian Change Point Detection, Hidden Markov Models et méthodes de détection de changement de distribution.

4. Exploitation des données textuelles :

embeddings de documents, classification NLP, extraction d'événements, modèles de langage, réduction dimensionnelle et clustering.

5. Ranking des prospects :

LambdaMART, pairwise learning-to-rank, gradient boosted ranking et optimisation de métriques de ranking telles que Precision@K et NDCG@K.

Une attention particulière sera portée à la calibration probabiliste, à l'explicabilité des prédictions et à la validation temporelle des modèles.

Bibliographie du sujet :

- Cox, D.R. (1972), Regression Models and Life-Tables, Journal of the Royal Statistical Society.
- Elkan, C. & Noto, K. (2008), Learning Classifiers from Only Positive and Unlabeled Data, KDD.
- Ishwaran, H. et al. (2008), Random Survival Forests, Annals of Applied Statistics.
- Katzman, J.L. et al. (2018), DeepSurv: Personalized Treatment Recommender System Using a Cox Proportional Hazards Deep Neural Network, BMC Medical Research Methodology.
- Burges, C. et al. (2005), Learning to Rank using Gradient Descent, ICML.
- Burges, C. (2010), From RankNet to LambdaRank to LambdaMART: An Overview.
- Adams, R.P. & MacKay, D.J.C. (2007), Bayesian Online Changepoint Detection.
- Hamilton, W.L. (2020), Graph Representation Learning, Morgan & Claypool.
- Devlin, J. et al. (2019), BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding.

Notation du sujet :

Commentaires :