



# SUJET STATAPP 310 - 2026-2027

**Sujet proposé par :** Bouyahia Mohamed Aymen - mohamed-aymen.bouyahia@lcl.fr

**Organisme :** LCL

**Catégorie :** Prédiction

**Sujet :**

**Détection de la Fraude Documentaire**

## Description du sujet :

La fraude documentaire constitue un enjeu important pour les établissements bancaires et assurantiels. Les documents transmis par les clients peuvent être falsifiés ou altérés de différentes manières : modification d'un montant ou d'une date, ajout ou suppression d'informations, modification d'une image ou d'une signature, réutilisation d'un document existant, etc.

Les méthodes traditionnelles de détection reposent notamment sur des règles métier, des contrôles de cohérence ou des techniques de traitement automatique des documents. Les progrès récents en intelligence artificielle, notamment en vision par ordinateur et en apprentissage profond, ouvrent de nouvelles possibilités pour détecter des altérations parfois difficiles à identifier automatiquement.

Le but de l'étude proposée est de développer une méthode algorithmique permettant d'identifier automatiquement les documents présentant des caractéristiques compatibles avec une fraude documentaire.

Les élèves pourront notamment étudier dans quelle mesure les caractéristiques visuelles et statistiques d'un document permettent de distinguer les documents authentiques des documents altérés. Différentes approches pourront être comparées, depuis des modèles de machine learning classiques jusqu'à des architectures de deep learning adaptées à l'analyse d'images et de documents.

Une attention particulière pourra être portée à la robustesse des modèles face aux différentes transformations que peuvent subir les documents : compression, changement de résolution, numérisation, photographie d'un document, bruit, recadrage ou modifications localisées.

L'objectif ne sera pas uniquement d'obtenir le meilleur taux de classification, mais également de comprendre quels signaux statistiques et visuels permettent aux modèles de détecter une fraude, ainsi que les limites et conditions de validité des méthodes proposées.

## Données du sujet :

Les données utilisées dans le cadre de cette étude seront constituées de documents authentiques et, lorsque cela sera possible, de documents présentant différents types d'altérations ou de falsifications.

Les données pourront notamment comprendre :

- ? des images ou scans de documents ;
- ? des documents authentiques servant de référence ;
- ? des documents artificiellement altérés selon différents scénarios de fraude ;
- ? des métadonnées ou caractéristiques liées aux documents, lorsque leur utilisation est pertinente ;
- ? des informations permettant de caractériser le type d'altération réalisé.

Les données pourront être issues de jeux de données publics complétés par des données construites dans le cadre du projet.

Les élèves pourront être amenés à réaliser différentes étapes de préparation des données : normalisation, extraction de caractéristiques, augmentation des données et construction d'échantillons d'apprentissage et de test.

**Modèles envisagés du sujet :**

VLM, CNN, Statistiques sur les pixels, ...

**Bibliographie du sujet :**

? Goodfellow, I., Bengio, Y. & Courville, A. ? Deep Learning.

? Dosovitskiy, A. et al. ? An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale.

? Liu, Z. et al. ? Swin Transformer: Hierarchical Vision Transformer using Shifted Windows.

? Travaux de recherche sur la document image analysis, le document forensics et la détection d'altérations d'images.

? Travaux récents sur les Vision Transformers et les modèles multimodaux appliqués aux documents.

**Notation du sujet :**

1

**Commentaires :**

Traitement d'image / détection de fraude totalement hors champ ENSAE, surtout en 2A.